Laporan Akhir

Mata Kuliah Teknologi Sensor

Perancangan *Soft Sensor* Deteksi Aktivitas Manusia Menggunakan Data *Gyroscope* dan Akselerometer dari Perangkat *Mobile*

Dosen Pengampu:

Prof. Ir. Nazrul Effendy, ST, MT, Ph.D., IPM.

Disusun oleh:

Kelompok 11

M. Nadhir Al Ghifary	(22/503570/TK/55030)
Natasya Aisyah Dini	(22/503833/TK/55079)
Melathi Andhara Putri	(22/503582/TK/55033)
Ahmad Fauzan Bakri	(22/497813/TK/54577)

PROGRAM STUDI TEKNIK FISIKA

DEPARTEMEN TEKNIK NUKLIR DAN TEKNIK FISIKA

FAKULTAS TEKNIK

UNIVERSITAS GADJAH MADA

YOGYAKARTA

2025

A. Deskripsi Dataset

1. *Tentang Dataset*

Dataset KU-HAR merupakan kumpulan data Human Activity Recognition (HAR) yang berisi informasi aktivitas fisik manusia yang direkam menggunakan sensor akselerometer dan gyroscope yang terpasang pada *smartphone*. Dataset ini terdiri dari 1945 data aktivitas mentah yang dikumpulkan dari 90 partisipan, dan menghasilkan 9185 subsample hasil ekstraksi. Semua data dalam dataset ini diambil dengan sampling rate sebesar 100 Hz tanpa proses filtering. Aktivitas yang tercatat dalam dataset ini mencakup gerakan fisik mulai dari gerakan sederhana seperti berdiri diam, berjalan, hingga gerakan yang lebih kompleks seperti naik tangga dan bermain tenis meja.

2. *Jumlah Aktivitas*

Terdapat total 12 aktivitas dalam dataset ini, yang meliputi berbagai aktivitas yang sederhana hingga kompleks yang diberi label beserta lama pengambilan data sebagaimana berikut

- *Stand* ➞ Berdiri diam (1 menit)
- *Sit* ➞ Duduk diam (1 menit)
- *Talk-sit* ➞ Berbicara sambil melakukan gerakan tangan saat duduk (1 menit)
- *Talk-stand* ➞ Berbicara sambil melakukan gerakan tangan saat berdiri atau berjalan (1 menit)
- *Stand-sit* ➞ Berdiri dan duduk secara berulang (5 kali)
- *Lay* ➞ Berbaring diam (1 menit)
- *Lay-stand* ➞ Berulang kali berdiri dan berbaring (5 kali)
- *Pick* ➞ Mengambil benda dari lantai (10 kali)
- *Jump* ➞ Melompat secara berulang (10 kali)
- *Push-up* ➞ Melakukan push-up penuh (5 kali)
- *Sit-up* ➞ Melakukan sit-up (5 kali)

- *Walk* ➞ Berjalan sejauh 20 meter (±12 detik)
- *Walk-backward* ➞ Berjalan mundur sejauh 20 meter (±20 detik)
- *Walk-circle* ➞ Berjalan mengikuti jalur melingkar (±20 detik)
- *Run* ➞ Berlari sejauh 20 meter (±7 detik)
- *Stair-up* ➞ Naik tangga (±1 menit)
- *Stair-down* ➞ Turun tangga (±50 detik)
- *Table-tennis* ➞ Bermain tenis meja (1 menit)

Dalam konteks perancangan *soft sensor* ini, ditetapkan lima aktivitas utama yang akan diprediksi sebagai parameter keluaran soft sensor dengan mempertimbangkan kelaziman aktivitas yang dilakukan sebagaimana berikut

- *Stand*
- *Sit*
- *Lay*
- *Walk*
- *Run*

3. *Masalah yang Dapat Diselesaikan*

Dalam konteks *Human Activity Recognition* (HAR), dataset ini menawarkan berbagai solusi untuk berbagai masalah yang berhubungan dengan pemantauan aktivitas fisik dan kesehatan secara real-time tanpa perangkat tambahan seperti

- Deteksi dini terhadap perubahan pola aktivitas yang dapat mengindikasikan gangguan kesehatan.
- Pemantauan aktivitas lansia atau pasien secara non-invasif dalam konteks perawatan jarak jauh.
- Identifikasi jenis aktivitas pengguna (seperti berjalan, duduk, berlari) hanya melalui *smartphone*.

4. *Fitur pada Dataset*

Pada setiap dataset, terdapat 8 fitur yang disediakan sebagaimana berikut

- Elapsed Time : Waktu sejak pengukuran akselerasi dimulai (sekon)
- X-Axis Acceleration : Akselerasi pada sumbu-X (m/s^2)
- Y-Axis Acceleration : Akselerasi pada sumbu-Y (m/s^2)
- Z-Axis Acceleration : Akselerasi pada sumbu-Z (m/s^2)
- Elapsed Time: Waktu sejak pengukuran gyro dimulai (sekon)
- X-Axis Gyro : Gyro pada sumbu-X (rad/s)
- Y-Axis Gyro : Gyro pada sumbu-Y (rad/s)
- Z-Axis Gyro : Gyro pada sumbu-Z (rad/s)

5. *Variabel Input (Hasil Ekstraksi Fitur)*

   Fitur pada dataset tidak dapat langsung digunakan karena sejatinya yang membedakan satu aktivitas dengan aktivitas lain adalah pola perubahan dan pola fluktuasinya. Oleh karena itu dilakukan ekstraksi fitur yang memanfaatkan fitur yang ada untuk mendapatkan nilai statistik per window (3 sekon data untuk data *stand, lay,* dan *sit* atau per 1 sekon data untuk data *walk* dan *run*). Adapun nilai statistik per window yang didapatkan adalah

   - *Mean*
   - *Standard Deviatan*
   - *Max*
   - *Min*

6. *Variabel Output*

   Variabel *output* pada perancangan soft sensor ini adalah label aktivitas sebagai keluaran prediksi aktivitas yang sedang dilakukan berdasarkan nilai gyro dan akselerasi yang sedang berlangsung.

B. Visualisasi Data

Dilakukan visualisasi data untuk melihat karakteristik sinyal dari masing-masing aktivitas. Data aktivitas dibagi menjadi dua kelompok berdasarkan panjang durasi pengambilan data, yaitu 60 sekon untuk aktivitas stand, sit, dan lay, serta 12 sekon untuk aktivitas walk dan run. Pemisahan ini dilakukan agar tampilan grafik lebih optimal dan

mudah dibaca, mengingat adanya perbedaan jumlah sampel dan rentang waktu antar aktivitas yang cukup signifikan.

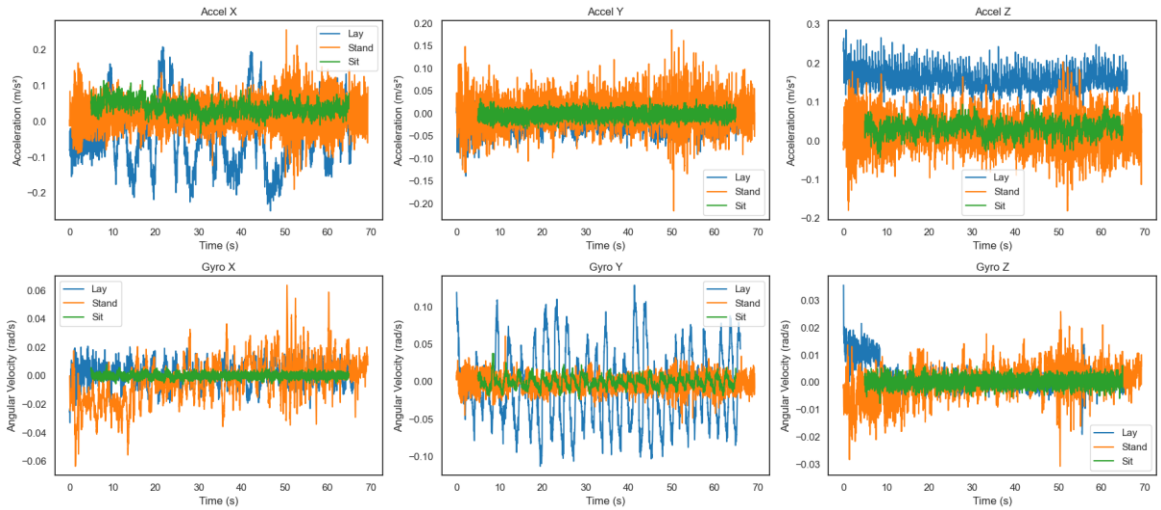

Gambar 1. Plot Data *Stand, Sit, dan Lay* untuk Nilai Akselerasi dan Gyro

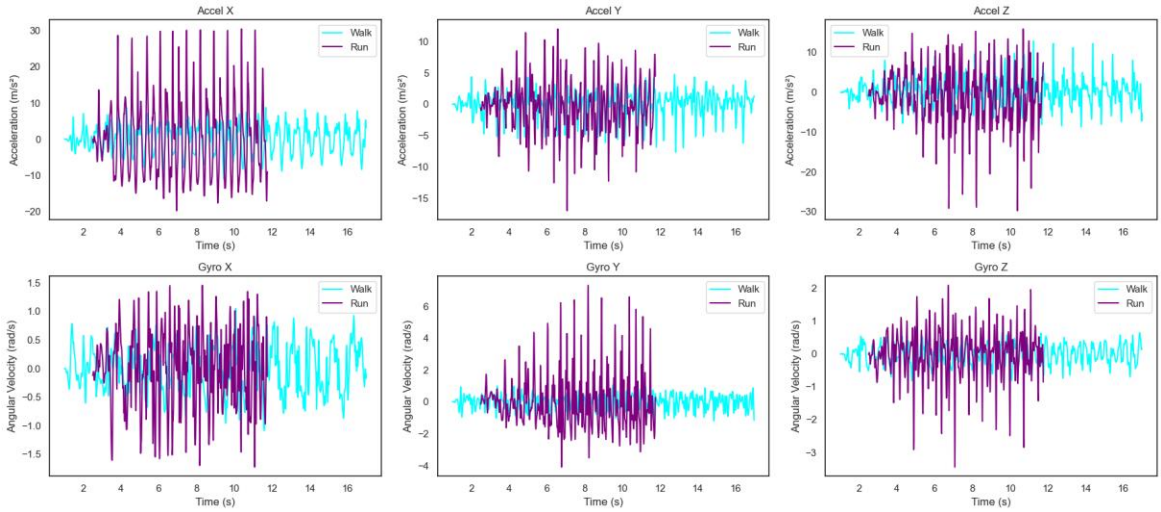

Gambar 1. Plot Data *Run* dan *Walk* untuk Nilai Akselerasi dan Gyro

Berdasarkan Gambar 1 dan Gambar 2, dapat dilihat bahwa perbedaan antar aktivitas ditunjukkan melalui pola guncangan, nilai guncangan, serta pola perubahannya dari waktu ke waktu. Aktivitas seperti *run* dan *walk* cenderung memiliki fluktuasi nilai yang lebih besar dan lebih dinamis dibandingkan *stand* atau *lay*. Oleh karena itu, data sesaat tidak cukup untuk merepresentasikan jenis aktivitas, justru yang lebih penting adalah pola

perubahannya dalam rentang waktu tertentu. Inilah yang menjadi dasar perlunya dilakukan proses feature extraction berbasis window waktu, agar karakteristik tiap aktivitas dapat diidentifikasi dengan lebih akurat.

C. *Feature Extraction*

Feature extraction diperlukan karena prediksi aktivitas tidak dapat dilakukan hanya berdasarkan data sesaat. Data sensor mengalami fluktuasi dalam rentang waktu tertentu, sehingga dibutuhkan proses ekstraksi fitur untuk menangkap pola perubahan tersebut. Diagram proses feature extraction dapat dilihat pada gambar berikut

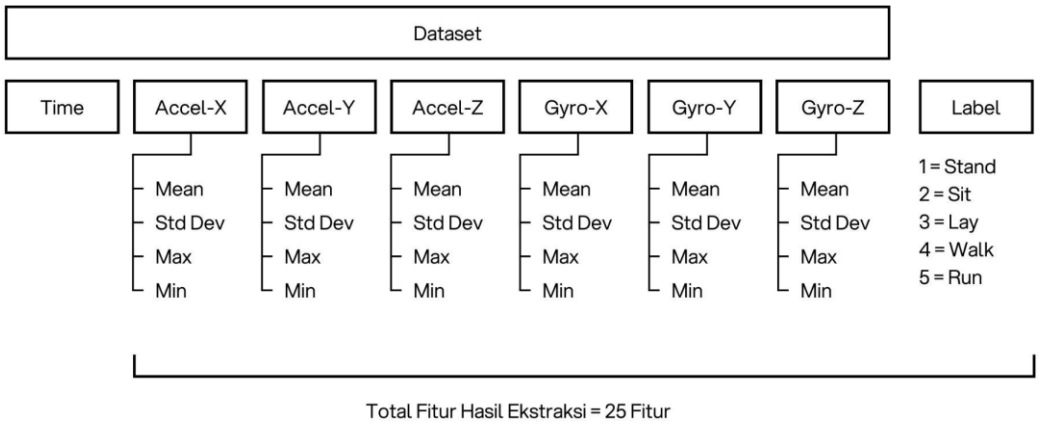

Gambar 3. Diagram Alur Proses Feature Extraction

Dataset semula memiliki 8 fitur yang terdiri dari dua waktu *elapsed time,* tiga aksis akselerasi, dan tiga aksis gyroscope. Dalam hal ini, digunakan satu nilai waktu saja. Adapun data akselerasi dan gyroscope dibagi menjadi beberapa window. Dalam setiap window waktu tersebut, diambil beberapa nilai statistik utama sebagaimana yang dijelaskan di awal (*mean, standard deviation, maximum value,* dan *minimum value)* sebagai fitur, dengan aturan:

- Aktivitas *stand*, *lay*, dan *sit*, proses ekstraksi dilakukan per 3 sekon (mengingat total durasi data: 60 sekon)
- Aktivitas *run* dan *walk*, ekstraksi dilakukan per 1 sekon (mengingat total durasi data: 12 sekon)

Selain nilai-nilai statistik tersebut, ditambahkan pula fitur label yang berfungsi merepresentasikan aktivitas yang dilakukan, dengan aturan klasifikasi sebagaimana yang disajikan pada Tabel 1.

Tabel 1. Penamaan Label untuk Pemodelan

No	**Nomor Label**	**Keterangan**
1	1	Stand
2	2	Sit
3	3	Lay
4	4	Walk
5	5	Run

Dengan melakukan *feature extraction* ini, diperoleh fitur baru baik yang diperoleh dari pengembangan fitur sebelumnya dan penambahan fitur sehingga didapatkan total 25 fitur yang dapat digunakan dalam pemodelan

D. Data Cleaning

Proses *data cleaning* dilakukan untuk memastikan bahwa data yang digunakan dalam pelatihan model berada dalam kondisi baik dan bebas dari nilai yang hilang. Setelah dilakukan pemeriksaan, ditemukan adanya beberapa baris data yang memiliki nilai kosong atau tidak lengkap sebagaimana ditunjukkan pada tabel berikut.

```
Jumlah NaN di tiap fitur:
mean_accel_x    0
std_accel_x     2
max_accel_x     0
min_accel_x     0
mean_accel_y    0
std_accel_y     2
max_accel_y     0
min_accel_y     0
mean_accel_z    0
std_accel_z     2
max_accel_z     0
min_accel_z     0
mean_gyro_x     0
std_gyro_x      2
max_gyro_x      0
min_gyro_x      0
mean_gyro_y     0
std_gyro_y      2
max_gyro_y      0
min_gyro_y      0
mean_gyro_z     0
std_gyro_z      2
max_gyro_z      0
min_gyro_z      0
label           0
dtype: int64
```

```
Jumlah NaN setelah di-drop:
           Fitur  Jumlah NaN
0   mean_accel_x           0
1    std_accel_x           0
2    max_accel_x           0
3    min_accel_x           0
4   mean_accel_y           0
5    std_accel_y           0
6    max_accel_y           0
7    min_accel_y           0
8   mean_accel_z           0
9    std_accel_z           0
10   max_accel_z           0
11   min_accel_z           0
12   mean_gyro_x           0
13    std_gyro_x           0
14    max_gyro_x           0
15    min_gyro_x           0
16   mean_gyro_y           0
17    std_gyro_y           0
18    max_gyro_y           0
19    min_gyro_y           0
20   mean_gyro_z           0
21    std_gyro_z           0
22    max_gyro_z           0
23    min_gyro_z           0
24         label           0

Jumlah data sebelum di-drop: 9856
Jumlah data setelah di-drop : 9854
```

Gambar 4. Terdapat Data Hilang di Beberapa Fitur (kiri) dan Data yang Sudah Bersih Setelah Data Cleaning (kanan) beserta Jumlah Baris Setelah Cleaning

Setelah proses pembersihan dilakukan sebagaimana Gambar 4, jumlah data mengalami sedikit pengurangan, dari semula 9.856 baris menjadi 9.854 baris, atau hanya berkurang 2 baris. Dengan demikian, data yang digunakan untuk proses *training* dan evaluasi dipastikan bersih dan layak untuk diproses lebih lanjut.

E. Analisis Statistik

1. *Analisis Distribusi Tiap Aktivitas*

Analisis distribusi data untuk lima aktivitas yang dipilih dalam dataset, yaitu *Stand* (berdiri), *Sit* (duduk), *Lay* (berbaring), *Walk* (berjalan), dan *Run* (berlari) bertujuan untuk memahami sebaran jumlah data untuk masing-masing aktivitas dan untuk memberikan wawasan mengenai ketidakseimbangan data yang mungkin mempengaruhi model prediksi.

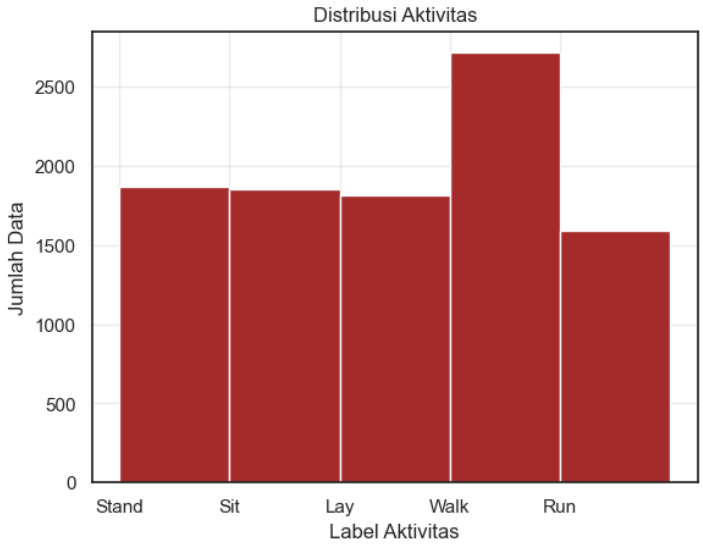

Gambar 5. Penyebaran Data untuk Tiap Aktivitas

Berdasarkan Gambar 5, dapat dilihat distribusi jumlah data untuk masing-masing aktivitas yang digunakan dalam penelitian ini. Aktivitas Walk memiliki jumlah data terbanyak yaitu 2.716 data, diikuti oleh Stand sebanyak 1.872 data, Sit sebanyak 1.855 data, Lay sebanyak 1.816 data, dan terakhir Run sebanyak 1.595 data. Perbedaan jumlah data ini disebabkan oleh perbedaan durasi pengambilan data masing-masing aktivitas. Walk memiliki variasi gerakan lebih banyak dalam waktu yang lebih singkat dibandingkan aktivitas lain. Meskipun terdapat ketidakseimbangan jumlah data antar aktivitas, selisihnya masih dalam batas wajar dan tiap aktivitas memiliki lebih dari 1500 data sehingga untuk proses pelatihan model.

2. *Feature Importance (Pengaruh Variable Input Terhadap Variabel Output)*

Grafik *Feature Importance* digunakan untuk mengevaluasi seberapa besar kontribusi setiap fitur dalam membedakan berbagai jenis aktivitas manusia yang tercatat menggunakan sensor akselerometer dan giroskop. Pada analisis ini, data hasil ekstraksi yang digunakan berisi data akselerasi dan rotasi tubuh pada sumbu X, Y, dan Z yang dicatat selama aktivitas fisik seperti berdiri, duduk, berbaring, berjalan, dan berlari. Fitur-fitur yang digunakan untuk pelatihan model antara lain:

standar deviasi akselerasi, rata-rata akselerasi, nilai maksimum dan minimum akselerasi, serta standar deviasi giroskop.

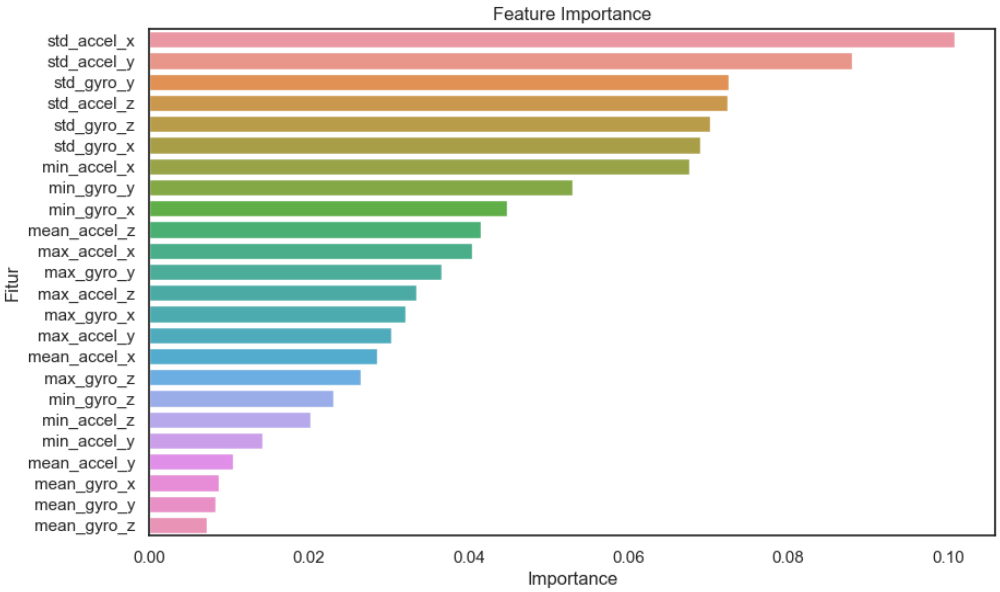

Gambar 5. *Feature Importance* Dataset

std_accel_x, **std_accel_y**, dan **std_accel_z** (standar deviasi akselerasi pada sumbu X, Y, dan Z) memiliki kontribusi terbesar dalam memprediksi aktivitas. Fitur-fitur ini mengukur variabilitas akselerasi, yang sangat penting untuk membedakan aktivitas dinamis seperti berjalan dan berlari. Adapun**mean_gyro_y** dan **mean_gyro_z** (rata-rata gyroskop pada sumbu Y dan Z) memiliki kontribusi yang lebih kecil. Ini menunjukkan bahwa rata-rata rotasi pada sumbu Y dan Z tidak memberikan informasi yang cukup kuat untuk membedakan aktivitas fisik dalam dataset ini.

Berdasarkan analisis *feature importace,* diperoleh hasil bahwa model ini lebih sensitif terhadap fluktuasi akselerasi daripada nilai rata-rata atau nilai ekstrem dari data. Di sisi lain, fitur seperti mean_gyro_y dan mean_gyro_z memiliki importance yang lebih rendah, dan karena itu kurang relevan dalam membedakan aktivitas.

F. Feature Engineering

Setelah proses *feature extraction* menghasilkan 25 fitur statistik utama dari sinyal akselerometer dan gyroscope, dilakukan tahap *feature engineering* guna mempersiapkan

data sebelum dimasukkan ke dalam model pembelajaran mesin. Tahap ini mencakup proses pemilihan fitur, pembagian data, serta penyesuaian struktur data agar sesuai dengan format input model.

Langkah awal yang dilakukan adalah pembagian dataset menjadi tiga subset: *data training, validation,* dan *testing*. Pembagian ini dilakukan dengan menggunakan fungsi train_test_split dari *library sklearn*, dengan rasio 64% untuk *training*, 16% untuk *validasi*, dan 20% untuk *testing*. Secara detail, data hasil pembagian subset dapat dilihat pada Tabel 2 sebagaimana berikut

Tabel 2. *Feature Engineering* untuk Membagi Data Menjadi Data Train, Test dan Validasi

Data Training	Data Test	Data Validasi
6306 (64%)	1971 (20%)	1577 (16%)

G. Model Building

1. Random Forest Classifier

Random Forest adalah salah satu algoritma *machine learning* yang membangun banyak *decision tree* dan menggabungkan hasilnya untuk menghasilkan prediksi. Pada prosesnya:

- Data akan dibagi secara acak untuk membangun beberapa decision tree.
- Setiap tree memberikan hasil prediksi.
- Hasil akhir ditentukan berdasarkan mayoritas voting (untuk klasifikasi)

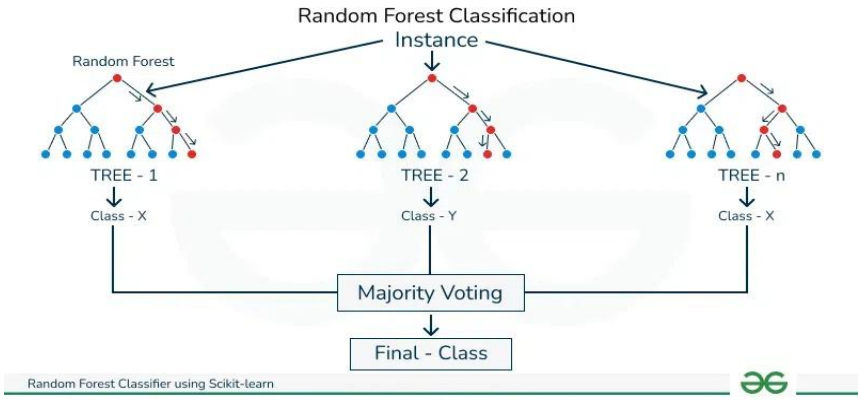

Gambar 6. Skema *Random Forest Classification*

Training data dilakukan dengan menggunakan *data train* sebagaimana yang telah didefinisikan pada *feature engineering.* Adapun parameter yang digunakan dalam pemodelan *Random Forest Classifier* dapat dilihat pada Tabel 3.

Tabel 3. Nilai Parameter yang Digunakan dalam *Random Forest Classifier*

Parameter	**Default Value**	**Penjelasan**
n_estimators	100	Jumlah *decision tree* yang akan dibuat dalam random forest.
max_depth	None	Batas kedalaman tiap *decision tree*. Jika *None*, pohon akan dibuat hingga daun.
min_samples_split	2	Jumlah minimal sampel untuk membagi *node*.
min_samples_leaf	1	Jumlah minimal sampel yang harus ada di *leaf node*.
random_state	42	*Seed* untuk pengacakan, supaya hasil bisa direproduksi.
n_jobs	None	Jumlah core CPU yang dipakai. Jika -1, gunakan semua *core*.

Model yang dihasilkan diuji menggunakan *data test* dan *data validation.* Adapun performa hasil uji dapat dianalisis melalui perhitungan matriks akurasi, presisi, recall dan f1-score. Hasil dari pengujian dapat dilihat pada Tabel 4/

Tabel 4. Hasil Uji Model *Random Forest Classifier*

Parameter	***Data Test***	***Data Validation***
Akurasi	0.954845	0.961319
Presisi	0.955405	0.962494
Recall	0.954845	0.961319
F1-Score	0.954917	0.961499

Hasil evaluasi menunjukkan performa model yang baik dan konsisten pada data uji dan data validasi. Akurasi model tercatat sebesar 0,9548 pada data uji dan 0,9613 pada data validasi. Nilai presisi, recall, dan F1-score juga berada di kisaran yang seimbang, masing-masing sekitar 0,955–0,962. Hal ini menunjukkan bahwa model mampu mengklasifikasikan aktivitas dengan akurat serta memiliki generalisasi yang baik terhadap data baru.

Selain itu, pengujian performa model dapat dilakukan dengan *confusion matrix* yang menganalisis ketepatan model dalam memprediksi jika dibandingkan dengan kesalahannya. Adapun hasil *confusion matrix* untuk model ini dapat dilihat pada gambar berikut.

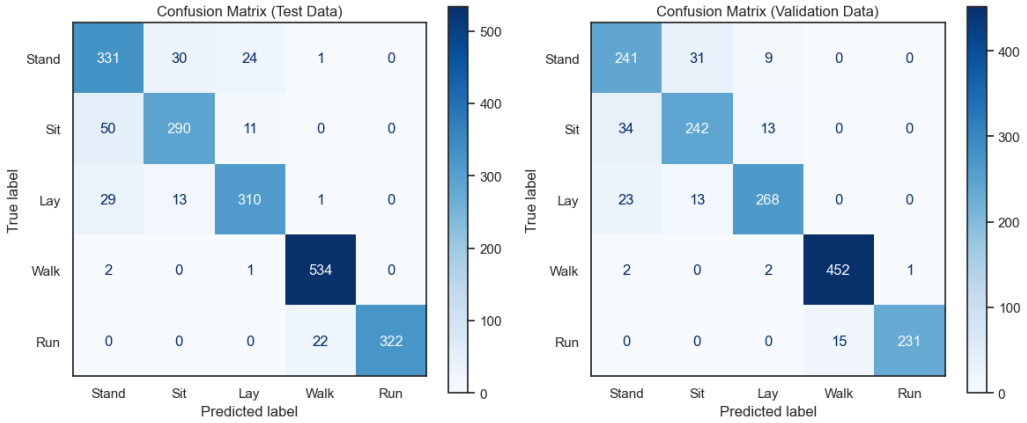

Gambar 7. *Confusion Matrix* Hasil Pemodelan *Random Forest Classifier*

Berdasarkan hasil *confusion matrix*, model menunjukkan performa klasifikasi yang baik dengan jumlah *true positive* dan *true negative* yang tinggi. Meskipun demikian, terdapat sejumlah kecil nilai *true negative* pada beberapa kelas aktivitas, yang menandakan adanya sedikit kesalahan klasifikasi terhadap kelas yang seharusnya negatif. Meski jumlahnya tidak signifikan, hal ini menunjukkan bahwa model masih memiliki ruang perbaikan untuk lebih mengoptimalkan prediksi pada kondisi tertentu.

2. Model K-Neighbours Classifier

Model *K-Nearest Neighbors (KNN)* digunakan sebagai salah satu pendekatan dalam klasifikasi aktivitas manusia berdasarkan data sensor gerak.

KNN merupakan algoritma non-parametrik yang bekerja dengan cara menghitung jarak antar titik data dan menentukan kelas dari data baru berdasarkan mayoritas label dari *k* tetangga terdekat.

Pemodelan dilakukan menggunakan data hasil feature engineering, di mana data pelatihan digunakan untuk membangun model, sementara data testing dan validasi digunakan untuk mengevaluasi performa model. Parameter utama yang digunakan adalah nilai k = 5, dengan pengukuran jarak menggunakan metrik Euclidean.

Tabel 5. Hasil Uji Model *KNN*

Parameter	***Data Test***	***Data Validation***
Akurasi	0.906646	0.909321
Presisi	0.908149	0.910938
Recall	0.906646	0.909321
F1-Score	0.906822	0.909734

Nilai-nilai metrik tersebut menunjukkan bahwa model KNN mampu melakukan klasifikasi aktivitas dengan cukup baik, dengan akurasi dan F1-score mencapai lebih dari 90% baik pada data uji maupun validasi. Hasil yang konsisten antara kedua dataset ini mengindikasikan bahwa model tidak mengalami overfitting dan memiliki kemampuan generalisasi yang baik.

Untuk mengevaluasi lebih dalam performa klasifikasi model K-Nearest Neighbors (KNN), digunakan *confusion matrix* yang menunjukkan distribusi prediksi model terhadap masing-masing kelas aktivitas. Evaluasi dilakukan pada dua subset data, yaitu data test dan data validasi, dengan lima kelas aktivitas yang diklasifikasikan: *Stand, Sit, Lay, Walk,* dan *Run.*

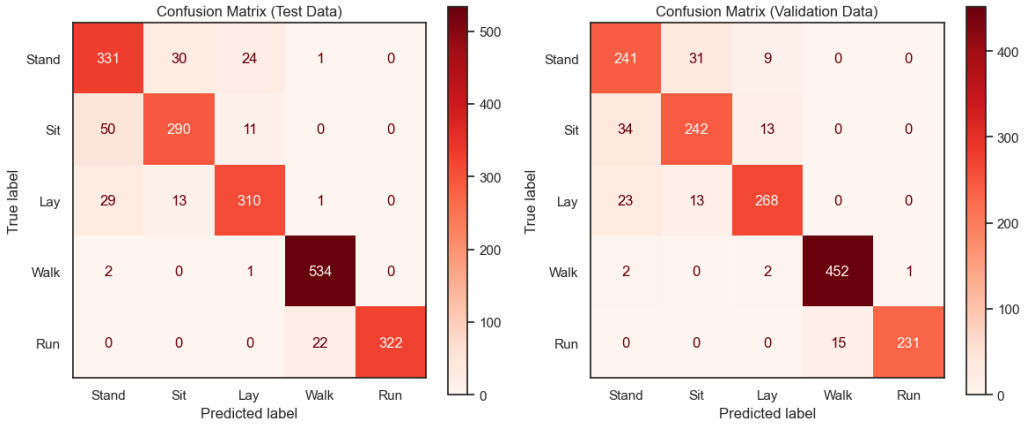

Gambar 8. *Confusion Matrix* Hasil Pemodelan *KNN*

Pada data test, model menunjukkan performa prediksi yang sangat baik khususnya untuk aktivitas dinamis seperti Walk dan Run, dengan jumlah prediksi benar yang sangat dominan. Di sisi lain, terdapat beberapa kesalahan klasifikasi pada aktivitas dengan postur statis seperti Sit, Lay, dan Stand, yang saling tertukar. Kesalahan ini diduga terjadi karena kemiripan pola sinyal sensor dalam kondisi tubuh yang relatif diam atau minim pergerakan.

Pola yang serupa juga terlihat pada data validasi. Aktivitas Walk dan Run tetap menjadi dua kelas dengan akurasi prediksi tertinggi, sementara kesalahan klasifikasi paling sering terjadi pada aktivitas Sit, Stand, dan Lay. Meskipun demikian, jumlah kesalahan relatif kecil dan tidak signifikan. Konsistensi pola prediksi antara data test dan validasi ini menunjukkan bahwa model KNN memiliki kemampuan generalisasi yang baik dan tidak mengalami overfitting.

H. Kesimpulan

Tabel 6. Perbandingan *Random Forest* dan KNN

Parameter	**Random Forest**		**K-Neighbour Classifier**	
	Data Test	**Data Validation**	**Data Test**	**Data Validation**
Akurasi	0.954845	0.961319	0.906646	0.909321
Presisi	0.955405	0.962494	0.908149	0.910938
Recall	0.954845	0.961319	0.906646	0.909321
F1-Score	0.954917	0.961499	0.906822	0.909734

Berdasarkan hasil pengujian yang telah dilakukan, model Random Forest menunjukkan performa yang lebih baik dibandingkan dengan metode K-Nearest Neighbor (KNN) dalam memprediksi aktivitas, dengan capaian akurasi sebesar 96%, sedangkan KNN hanya mencapai 91%. Perbedaan performa ini menunjukkan bahwa Random Forest lebih mampu menangkap pola kompleks dari data yang digunakan. Tahapan selanjutnya, model prediksi ini dapat dikembangkan lebih lanjut dan di-deploy ke perangkat mobile seperti handphone, sehingga dapat berfungsi sebagai soft sensor yang mampu memprediksi aktivitas pengguna secara real-time berdasarkan data sensor yang tersedia. Dengan demikian, sistem ini berpotensi diterapkan dalam berbagai aplikasi monitoring aktivitas berbasis mobile dengan tingkat akurasi yang tinggi

I. Daftar Pustaka

[1] A.-A. Nahid, N. Sikder, and I. Rafi, "KU-HAR: An Open Dataset for Human Activity Recognition," *Mendeley Data*, vol. 3, 2020. [Online]. Available: https://doi.org/10.17632/45f952y38r.3

[2] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324

[3] T. Cover and P. Hart, "Nearest Neighbor Pattern Classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967, doi: 10.1109/TIT.1967.1053964.

[4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html

J. Lampiran

Video Demo

https://youtu.be/rMV_IjNqGzE

Video Presentasi

https://youtu.be/Bgw_GsXl5WM